

합성 주행 데이터 생성 — 상세 정리 (참조 문헌 포함)

팀 공유용 · 2026-08-02 · 발송 답변서 3번의 "부록에 제시했습니다"에 해당하는 내용의 통합판 · 근거 원장: 주행로그_생성근거_정리.md · 출처부록

요약 (세 문장)

데이터는 사람(문헌 기반 설계) → AI(인물 구조 생성) → 결정론 엔진(숫자 전개) → 통계(유형 분해) 네 단계로 만들어집니다. AI가 정하는 것은 인물의 생활 구조뿐이고, 빈도·거리·위험을 같은 통계 파라미터는 전부 사람이 문헌 분포 위에 배치한 설계값입니다. 어느 값이 문헌이고 어느 값이 설계인지를 값별로 표로 가릅니다.

1. 전체 구조 — 4단계 체인

단계	하는 일	주체	통계 장치
① 유형 정의	문헌 3축을 조합해 6개 운전자 유형 설계	사람	축별 문헌 명시 (2절)
② 인물·프로필	유형을 60명 인물로 구체화, 생활 구조 생성	AI(LLM)	스키마 검증·재시도, 1회 생성 후 캐시 고정, 실존 지명 금지
③ 이벤트 전개	월별 방문·거리·위험행동의 실제 숫자 생성	결정론 엔진	시드 고정(sha256), 파라미터는 사람이 설정 (4절)
④ 위험 유형 분해	위험행동을 급제동/과속/급가속으로 표시	통계(TAAS)	표시 전용 — 판정 미진입 (5절)

산출 규모: 60명 × 3환경(도심·교외·광역) = 180 시나리오 · 14개월(기준선 2 + 평가 12) · 주행 로그 80,032건 · 파티션 개발 108 / 검증 36 / 홀드아웃 36.

2. 1단계 — 유형 정의와 문헌 근거

유형은 고령 운전자 문헌에서 반복 확인되는 세 가지 행동 축의 조합입니다.

축	문헌 근거	등급
이동범위 축소	LongROAD (n=2,990): 축소 이동범위 22.6% · 자기규제 1순위 야간 회피 58.8% (n=1,557)	◎
만성 위험행동	CMT UBI 백서 2023 (n≈10만): 행동 5분위 최상·최하위 클레임 빈도 약 3배 — △ 전 연령 데이터, 고령 한정 근거와 역할 구분	◎
운전 패턴 변화	DRIVES (Neurology 2025, n=298): 차이는 시간에 따른 궤적에서 발현, 주행 변수만으로 인지 판별 AUC 0.82 · Bayat 2021 (n=139)	◎

세 축의 조합으로 6개 유형 — 안정 저주행형 / 생활권 내 위험행동형 / 이동변화·안전유지형(오탐 대조군) / 이동·위험 동시변화형(케어 대상) / 복수 생활권형 / 광역 이동·안전형. 통과해야 할 케이스뿐 아니라 실패해야 할 케이스(대조군)를 처음부터 설계에 포함한 것이 검증 (6절)의 전제입니다.

인물화(60명: 이름·나이·가구·서사)는 NVIDIA Nemotron-Personas의 방법론을 따라 팀이 자체 정의 — 데이터셋을 가져온 것이 아닙니다.

3. 2단계 — AI 프로파일: 무엇을 만들고, 무엇을 못 만드나

AI가 생성하는 것 (인물별 이동 프로파일):

- 자주 가는 장소들 (전원 합성 라벨 — 실존 지명 금지 가드로 재생성 검증)
- 장소별 방문 비중, 방향(bearing), 거리대(band)
- 패턴이 변하는 시점(change_month)과 계기 서사

통제 장치: 구조(스키마) 검증 통과분만 사용, 실패 시 재생성 · **1회 생성 후 캐시로 저장소에 커밋**(매 실행 재생성 아님) · 거리대는 유형 역할로 강제(계약 안전) · 위험 크기는 아키타입에 고정(통제변수).

AI가 정하지 않는 것: 방문 빈도·주행거리·위험률의 수치, 판정 규칙과 가중치, 케어 임계 — 전부 사람 설정. AI의 다른 역할은 판정 결과를 문장으로 옮기는 리포트 하나뿐입니다.

4. 3단계 — 파라미터와 문헌 앵커 (핵심)

원칙: 문헌이 숫자를 주는 게 아니라 분포를 주고, 우리 값이 그 분포의 어디에 있는지를 표로 제시합니다.

4-1. 월 방문 수 — 설계값 13 / 24 / 32 / 40 / 42

문헌 실측 (단위 주의 — 트립≠방문지, "집→마트→집"은 트립 2·방문지 1. 국내 목적통행의 48%가 귀가이므로 방문지 $\approx$ 통행 $\times 0.52$ 로 환산):

출처	대상	값 → 월 방문지 환산	등급
가구통행실태조사 2006 수도권 (마강래·윤영호 2009)	65세+ n=49,380	0.79 통행/인·일 → 12.5곳	◎
한국교통연구원 2001, 5대광역시	65세+	0.83 통행/인·일 → 13.1곳	△
LongROAD (Molnar 2019, AAA)	65~79세 n=2,131, GPS 12개월	트립 119.4/월 · 운전일 22.5일/월	◎
DRIVES (Roe 2019)	평균 73.1세	고유 목적지 39.4~44.4/월	◎
Bayat 2021	평균 75.7/79.1세 n=139	고유 목적지 34.8~38.2/월	◎

우리 값의 위치:

유형	설계값	문헌상 위치
생활권 내 위험행동형	13	국내 5대광역시 실측 13.1과 거의 일치
안정 저주행형	24	국내 중상단
이동변화형·동시변화형	32	국내 상한(28.8)과 해외 하단(35) 사이
광역 이동형 / 복수 생활권형	40 / 42	해외 코호트 평균대(35~44) 안

국내(무통행자 포함, 하향)와 해외(주 1회 이상 운전자만 등록, 상향)의 표본 정의 차이로 두 범위가 벌어지며, **우리 6개 값이 그 사이를 잇습니다.**

4-2. 야간 비중 — 설계값 0.06~0.18

출처	정의	값	등급
LongROAD (Molnar 2017/2019)	태양고도 96° 초과 구간이 트립의 80% 이상	평균 6.7% (SD 5.1, 관측 범위 0~39.3)	◎
Aschenbrenner 2022	일몰 이후 출발	54.5%	◎

△ 정의를 빼면 두 문헌이 7배 어긋납니다 — 야간 비중은 반드시 정의와 함께 인용. 우리 설계값(0.06~0.18)은 LongROAD 정의 기준 범위 안, 상위 절반.

4-3. 위험행동 강도 — 설계값 0.03(안전)~0.72(위험) — 여기만 성격이 다름

'트립 중 위험행동 비율'이라는 우리 단위로 보고한 고령자 문헌은 부재를 확인했습니다(거리당 건수 문헌만 존재). 그래서 이 측은:

- 1. 방향성만 문헌 — 안전<<위험 (CMT 상·하위 3배)
 - 2. 값 자체는 설계값 — 유형 간 대비를 만드는 통제변수
 - 3. 산출을 문헌 단위로 환산해 검증 — 우리 산출 0.00~0.89건/100km는 LongROAD RDE 실측(0.35g 기준 5.3건/1,000mile = 0.33건/100km)과 같은 자릿수. 참조: Hill 2020 (≥0.35g, 5.42/1,000mile) · Hill 2021 (≥0.4g, 1.16)
- △ 급제동은 반드시 g 임계와 함께 인용 — 같은 코호트에서 0.35g면 5.3건, 0.75g면 0.005건으로 1,000배 차이.

4-4. 연간 주행거리 — 환경별 평균 2,000 / 3,101 / 6,148km

국내 연령별 주행거리 통계는 부재를 확인했습니다(교통안전공단·국토부·보험개발원·KTDB·소비자원 — 보험연구원 2025-13이 부재를 저자 명시, p.17·24). 해외 앵커:

출처	값	등급
FHWA (NPTS, 미국 65세+)	연 12,305km (남 16,583 / 여 7,701)	◎
Candrive (Marshall 2023, 캐나다 70세+)	연 11,017.6km (SD 6,959.9) — 코호트 내 변동성 큼	◎ (원문 PDF)
Ozcandrive (Charlton 2018, 호주 75세+)	1년차 8,993km → 5년차 6,787km	△
LongROAD (Betz, 미국 65~79세)	연 3,000mile 미만 = 6.38%	◎

우리 값은 해외 평균보다 낮게 — 국내 도시 구조·저주행 현실을 반영해 재보정한 설계값입니다(저주행 편향 문헌: Langford 2013, 연 5,000km 미만군의 km당 위험 상승, △).

4-5. 전개 메커니즘 — 숫자가 실제로 찍히는 방식

사람×월 단위 시드(sha256)로:

- 1. 그 달 방문 수 = 유형 기준값 ± 1 (sparse 유형은 -3, 최소 3회)
- 2. 각 방문을 프로필의 목적지 비중대로 추천
- 3. 좌표 = 목적지 중심 + 주차 산포(환경별 jitter), 날짜 흩뿌림
- 4. 위험행동 = 트립마다 유형별 확률(risk_rate)로 추천
- 5. 트립 거리 = 거리대 기하(지도 좌표와 동일 소스) + 소변동

같은 입력이면 언제 실행해도 동일 결과 — 재현성이 검증의 전제입니다.

5. 4단계 — 위험 유형 분해 (표시 전용)

발생한 위험행동을 급제동/과속/급가속으로 나누는 구성비:

- **정의 표준**: eTAS(한국교통안전공단 운행기록분석시스템)의 위험운전행동 정의를 따르도록 설계. ⚠ 합성 엔진에 eTAS 임계(g값) 구현은 없음 — "유형 정의는 eTAS 표준, 합성 빈도는 LongROAD 앵커, 실서비스에서 eTAS 임계 적용"이 정확한 문장
- **구성비**: TAAS 교통사고분석시스템 원천 CSV(2010-2024, 시군구 전수) → 산출 코드(taas_risk_weights.py) → **44.6 / 42.4 / 13.0%**. 과속 항목은 2021년부터 원천 미집계라 2010-2020 평균 기준치 사용(provenance에 기록)
- **표시 전용** — 판정 미진입: 구성비를 교체하고 180건을 재판정해도 **diff 0건** (테스트로 고정)

6. 검증 — 왜 이 데이터를 믿을 수 있나

장치	내용
라벨 차단	판정 함수는 유형·시나리오 라벨을 입력받지 않음 — 생성된 이벤트만 봄
오탐 대조군	이동만 변한 30건: 이동 임계 초과 191 케이스-월 에도 케어 발동 0건 — 유리하게 설계된 구조였다면 이 경계에서 오탐 발생
재현성	시드 고정 — 동일 입력 = 동일 결과, 전 과정 재실행 가능
파티션	개발 108 / 검증 36 / 홀드아웃 36 — 규칙은 어느 파티션에도 적합하지 않음
정직 한계	이 시뮬레이션이 확인하는 것은 예측력이 아니라 판정 로직의 일관성 . 절대 수치가 현실 재현이라 주장하지 않으며, 실데이터 확보 시 파라미터를 실측 분포로 교체(검증 로직은 재사용)

7. 인용 시 주의 (금지·필수 병기)

- 야간 비중 — **정의(태양고도/일몰) 없이 인용 금지** (7배 차)
- 급제동 — **g 임계 없이 인용 금지** (1,000배 차)
- CMT 3배 — 전 연령 데이터임을 병기, 고령 한정 근거와 역할 혼용 금지
- DRIVES — "사고 이전"이 아니라 **"진단·자각 이전"**
- Nemotron — 데이터셋 사용이 아니라 **방법론 자체 정의**
- eTAS — 합성을 eTAS 임계로 생성했다고 말하지 않기
- 우리 확률값(빈도·위험률) — 경험적 분포가 아니라 **설계값임을 인정**하고, 문헌 분포에서의 위치로 방어

근거 원장: final/근거자료/주행로그_생성근거_정리.md (축별 상세 표) · final/08.출처부록_주제별.md (전체 등급) · 확정수치카드 · 발송 답변서 3번