

부록 B 해설 — 수식과 2개월, 쉽게 풀기

팀원용 · 부록 B의 2단(수식·파라미터)과 3단(왜 2개월)을 발표자가 말로 풀 수 있는 수준까지 해설 · 2026-08-02 · 생활권 파트

이 문서는 부록 B 장표의 2단(표준 DBSCAN을 MASIL 규칙으로 치환) 과 3단(왜 기준선은 2개월인가) 을 처음 보는 팀원 기준으로 폼니다. 장표에는 결론만 실려 있고, 여기에는 그 결론이 나온 길이 있습니다.

1부. 2단 풀이 — 수식 세 개가 하는 말

장표의 수식 박스는 세 개(A→B→C)이고, 각각 한 문장으로 줄이면:

A. 표준 DBSCAN: "가까이 모인 점이 충분히 많으면 거기가 자주 가는 곳" B. 우리 치환: "'많으면'을 점 개수가 아니라 서로 다른 방문일 수로 센다" C. 상품 반경: "거점이 확정된 다음에, 원의 크기는 따로 정한다"

A. 표준 DBSCAN — 정해야 할 값이 두 개

$N_{\epsilon}(p) = \{ q : d(p, q) \leq \epsilon \}$ ← 점 p에서 반경 ϵ 안의 이웃들
 $Core(p) \Leftrightarrow |N_{\epsilon}(p)| \geq min_samples$ ← 이웃이 min_samples개 이상이면 거점 점

말로 풀면: 도착지점 하나하나를 보면서 "이 점 주변 ϵ 미터 안에 다른 점이 min_samples개 이상 있나?"를 묻고, 그렇다면 그 일대를 하나의 군집(거점)으로 묶습니다. 그래서 정해야 할 값이 ϵ (몇 미터가 '가까이'인가)과 min_samples(몇 개가 '충분히'인가) 두 개입니다.

B. 우리가 바꾼 것 — 점 개수의 함정

표준 방식의 함정: 점 개수를 세기 때문에, 하루에 마트를 세 번 들르면 점이 3개 찍혀 하루 만에 '거점'이 될 수 있습니다. 생활권은 "반복되는 생활"을 담으려는 것이므로 이걸 우리 목적과 안 맞습니다.

$Core_MASIL(p) \Leftrightarrow unique_days(N_{\epsilon}(p)) \geq 3$

이웃 점들의 서로 다른 방문 날짜가 3일 이상일 때만 거점으로 인정합니다. 같은 날 재방문은 1일로만 계산 — "며칠에 걸쳐 반복해서 왔는가"가 거점의 정의가 됩니다.

C. 상품 반경 — 군집이 끝난 다음의 별도 단계

$r_h = \max(500m, \min(P90_h, 2km))$

거점 h가 확정되면, 그 거점의 원 크기는 위 공식으로 따로 정합니다. 예시로 바로 감이 옵니다:

그 거점의 P90 실측	최종 반경	어느 항이 작동했나
420m	500m	하한(보호)
800m	800m	실측 그대로
3.1km	2km	상한(가드레일)

파라미터 사전 — 다섯 개 전부

값	무엇인가	왜 이 값인가	어디서 왔나
$\epsilon = 260m$	몇 미터 안이면 '같은 곳'으로 묶나 (탐지 전용)	건물뿐 아니라 주변 주차 공간까지 담는 거리	위치데이터 연구 관행 200~300m의 중간값 (Zheng 200m·Montoliu 200~300m를 참고한 제안 시작값 , 논문 직접값 아님) · 실데이터 축적 후 k-거리 실측으로 재산정
서로 다른 3일	며칠 반복해야 '거점'인가	우연 방문(집들이 1회)과 단골(격주 병원)의 구분선	Isaacman 2011 — 60일 관찰의 5% = 3일, 동일 기준
Core 500m	거점마다 보장하는 최소 원	측정이 고객에게 불리한 쪽으로 작동하지 않게 하는 보호 하한 — 규칙적인 고객의 P90이 150m로 나오면 길 건너 주차(200m)가 '생활권 밖'이 되는 오염을 막음	국내 원안의 상품 원칙
P90	그 거점 방문 거리의 90퍼센타일	"방문의 90%가 들어오는 반경" — 장날 한 번의 원거리 주차에 원이 4배로 커지지 않게 (최댓값·평균을 안 쓰는 이유)	개인 실측 (사람×거점마다 다름)
2km 상한	원이 무한정 커지지 않게	특이 패턴 하나가 존을 뺏기하는 것 방지	설계 가드레일

세 반경을 절대 섞지 말 것 — 역할이 다릅니다:

260m = 점을 묶는 자(탐지) · **500m** = 보장(약속) · **P90** = 실측(측정)

260m는 원의 크기에 **들어가지 않습니다**. 원 공식은 500m와 P90과 2km로만 구성됩니다. "eps를 바꾸면 생활권이 커지나요?" → 아니요, 거점이 몇 개로 묶이는지만 달라지고 원 크기는 그대로입니다.

흐름 한 줄: 점 묶기(260m·3일) → 거점 확정 → 원 씌우기(max(500, min(P90, 2km))) → 원들의 합집합 = 생활권.

보충 — "k-거리 실측으로 재산정"이 뭔가

사전에서 260m의 갱신 계획으로 언급한 그 방법입니다. 세 가지만 알면 됩니다.

- ① **k가 뭔가**. k번째 이웃(k-th nearest neighbor)의 k입니다. k-거리 = 어떤 점에서 **k번째로 가까운 점까지의 거리**. DBSCAN 원논문 (Ester et al. 1996)이 ϵ 을 정하는 표준 방법으로 제시한 게 이 k-거리 분포입니다.
- ② **우리 버전에서 k=2인 이유** — **3일 규칙에서 자동으로 나옵니다**. 거점이 되려면 서로 다른 3일이 필요하니, 어떤 방문점이 거점에 들려면 자기(1일) 외에 **다른 날 이웃이 2개 ϵ 안에 있어야 합니다**. 그래서 재는 값은:

각 방문점에서, **다른 날 방문한 점들 중 두 번째로 가까운 것까지의 거리**

예시: 같은 마트를 화·금·월요일에 갔는데 주차 위치가 매번 달라서, 화요일 방문점에서 다른 날 방문점까지가 40m, 120m라면 → 그 점의 k-거리는 **120m** ("이 거점을 살리려면 ϵ 이 최소 120m는 돼야 한다"는 뜻).

③ **언제, 어떻게 쓰나** — **판정할 때가 아니라 값을 갱신할 때, 한 번**. 파일럿에서 실고객 데이터가 쌓이면 전체 방문점의 k-거리를 **지역 단위로 모아서** (개인별로는 표본이 적어 흔들림) 분포를 봅니다. 재방문 산포는 수십~이백 m에 몰리고 우연 방문은 수백 m~수 km로 튀는데, **그 두 무리 사이의 경계가 ϵ 이 됩니다**. 결과는 "반경 몇 미터"라는 설명 가능한 상수 하나 — 260이 맞았는지, 230으로 바뀌어야 하는지를 데이터가 답해주고, 이후 판정은 그 고정값으로 둡니다. 요율을 손해줄 데이터로 재산정하는 것과 같은 **정기 캘리브레이션 패턴**입니다.

시점 (덱 로드맵 기준): 파일럿(0~6개월) 4~6개월 차에 1차 측정 — 지역 단위 분포라 표본 요구가 낮아, 고객 수백 명 × 2~3개월이면 방문점 수만 개로 충분합니다. **Scale-up 진입 시(6개월 차)부터 반영** — 이후 가입·갱신 고객의 생활권 형성에 갱신값 적용, 기존 고객의 계약 기간 중 소급 변경은 없음. 이후 **연 1회 재점검**.

HDBSCAN이랑 뭐가 다르냐는 질문이 나오면 — 좋은 질문이고, 재는 양은 같습니다(HDBSCAN의 core distance가 바로 k번째 이웃 거리). 차이는 그 값을 어디에 두느냐입니다: HDBSCAN은 **점마다, 판정할 때마다** 달리 써서 장소마다 기준이 달라지고, 우리는 **전체에서 한 번 재서 모든 고객에게 같은 상수로** 씁니다. 지키려는 게 "모든 고객에게 같은 문장"이라는 판정의 일관성이라서요. 덤으로 우리 k=2는 고르는 값이 아니라 3일 규칙에서 유도되므로, 설명 사슬이 끊기지 않습니다.

2부. 3단 풀이 — "왜 2개월인가"를 4단계로

0단계. 문제 설정

제일 뚝한 생활 거점을 생각합니다 — **격주로 가는 병원, 월 2회**. 이런 곳도 생활권에 들어와야 "정기 통원자가 병원 갈 때마다 생활권 밖" 같은 억울한 상황이 없습니다. 질문: **월 2회짜리 거점을 놓치지 않으려면 며칠을 관찰해야 하나?**

1단계. 규칙 되새김

거점이 되려면 **서로 다른 3일** 방문이 필요합니다 (1부의 그 규칙).

2단계. 왜 그냥 산수로 안 되나

"월 2회 × 2개월 = 4일이니까 2개월이면 되네"로 끝나지 않는 이유: 방문은 매달 정확히 2회가 아니라 **들쭉날쭉**합니다. 어떤 달은 1번, 어떤 달은 3번. 그래서 "평균 월 2회로 불규칙하게 일어나는 방문이, 관찰 기간 T 동안 3일을 넘길 **확률**"을 계산해야 합니다.

3단계. 확률 계산

이런 "평균은 알지만 불규칙한 사건의 횟수"를 다루는 표준 도구가 푸아송 분포입니다. 평균 월 2회($\lambda=2$)로 두고 T개월 동안 3일 이상 방문할 확률:

$$P(N \geq 3) = 1 - e^{-(\lambda T)} \cdot [1 + \lambda T + (\lambda T)^2 / 2]$$

관찰 기간	월 2회 거점이 잡힐 확률	해석
1개월	32.3%	세 번 중 두 번은 놓침 — 너무 짧다
2개월	76.2%	4분의 3 이상 잡힘 — 채택
3개월	93.8%	+17.6%p 더 잡히지만, 서비스 시작이 한 달 늦어짐

4단계. 판단

2개월 = 포착률과 시작 속도의 균형점. 1개월은 뚝한 거점을 3번 중 2번 놓치고, 3개월은 얻는 것보다 잃는 것(고객이 한 달 더 기다림)이 커집니다.

이 계산의 근거와 정직한 한계

"월 2회"라는 가정의 출처 (국내 공식 통계):

- 건강보험 통계 2022 — 65세+ 월평균 입내원 **3.75일**
- 노인실태조사 2023 — 경로당 이용자 **주 2.9회**
- 소비자원 2024 — 고령운전자 최빈 운전 빈도 **주 3~5회** (36.7%)

→ "가장 뜸한 생활 거점도 월 2회쯤은 간다"는 가정이 국내 실측 범위 안.

선례 (Isaacman 2011): 통신 위치데이터로 반복 방문지를 찾은 대표 연구가 **60일 관찰에서 "전체 일수의 5% = 3일"** 기준을 썼습니다 — 우리와 같은 창, 같은 문턱. 단 **통신 데이터 연구이지 운전 연구가 아니므로** "단골 지점을 찾는다는 문제 구조가 같아 방법론으로 참고"까지만 말합니다.

정적 라벨 (장표의 "실측 포착률·최적값 아님"이 뜻하는 것):

1. 76.2%는 **실측이 아니라 가정(월 2회·불규칙) 위의 계산**입니다
2. "3일 문턱"과 "월 2회"를 정해놓고 역산한 것이라, **그 두 값 자체가 옳다는 증명은 아닙니다**
3. 2개월은 유일한 최적값이 아니라 **합리적 범위 안의 값**입니다 — 발송된 답변서 5번에 이 문장 그대로 있습니다

자주 나오는 질문 세 개

Q. "76.2%는 실측인가요?" → 아니요, 내부 추정입니다. 가정(월 2회)은 국내 통계에 앵커했고, 실측 포착률은 파일럿에서 잹니다.

Q. "기준선 2개월이랑 케어의 '직전 2개월'이랑 같은 건가요?" → 다른 장치입니다. 기준선 2개월 = 생활권을 **만드는** 고정 기간(이 문서의 주제). 직전 2개월 = 케어가 급변을 재려고 매달 **굴리는** 비교 창. 숫자만 같고 역할이 다릅니다.

Q. "왜 3개월로 안 했나요?" → 포착률 +17.6%p를 얻는 대신 고객의 서비스 시작(생활권 형성)이 한 달 늦어집니다. 그 교환이 손해라고 판단했고, 이것도 파일럿 재보정 대상입니다.

한 장 요약 (발표자 치트시트)

- **260m** — 점을 묶는 자. 연구 관행 200~300의 중간값, 추후 k-거리 실측으로 교체
- **k-거리 실측** — 판정용 아님. 파일럿 후 '다른 날 2번째 이웃 거리'를 지역 단위로 모아 ϵ 을 데이터로 재산정하는 1회성 캘리브레이션
- **서로 다른 3일** — 거점의 정의. Isaacman 60일의 5%와 동일 기준
- **500m** — 보호 하한. 측정이 고객에게 불리하게 작동하지 않게
- **P90** — 개인 실측. 장날 한 번에 원이 안 커지게 90퍼센타일
- **2km** — 상한 가드레일
- **2개월** — 월 2회 거점 포착 76%가 되는 최소 창 (1개월 32% / 3개월 94%인데 한 달 늦음)
- 원 공식에 260m는 **없다**: $r = \max(500m, \min(P90, 2km))$
- 76.2%는 실측 아님 — 국내 통계에 앵커한 **내부 추정**

근거 전문: 현장 피드백 답변서(발송본) 5번 · 출처부록 5장(관찰 창 선례) · 확정수치카드